数据挖掘导论2026大作业

概述：运用聚类、异常检测与回归方法完成四项必做任务，并自选一项拓展作业。

数据集：https://bhpan.buaa.edu.cn/link/AA29E06E1DF21C419D9A1F56FFB409B665

评分：必做任务共100分；拓展作业最高加10分；总成绩按100分封顶。

必做任务（全部完成，每项25分）

任务1（25分）：图像无监督聚类（数据集为Cluster.zip）
任务2（25分）：图像异常检测（数据集为Image_Anomaly_Detection.zip）
任务3（25分）：时间序列预测（数据集为weather.csv）
任务4（25分）：无监督疾病判断（数据集为thyroid.zip）

拓展作业（自愿选做，二选一，最高加10分）

拓展一：跨模态异常检测
拓展二：企业财务问答Agent系统（数据集为FinanceQA.zip）

组队：3人一组

提交：报告PDF + 代码仓库链接（GitHub/GitLab） + 分工说明PDF

报告说明方法、实验结果与分析；代码README写明环境配置和运行方法。

数据挖掘导论2026大作业

任务 1：聚类任务　　25% Score

使用合适的聚类算法，对所给的图像数据集进行聚类。

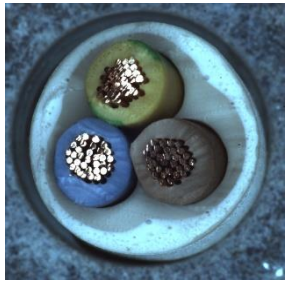
1.0：问题的形式化描述　　5% Score

1.1 ：**如何**处理图像特征　　5% Score

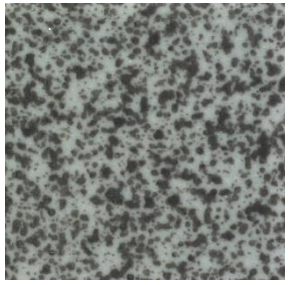
1.2 ：选择合适的聚类算法　　10% Score

1.3 ：评估你的聚类效果　　5% Score

图像聚类数据集Cluster：**数据位于**dataset/**内**，**共6个**类别，每类图像100张。类别介绍：



cable



tile



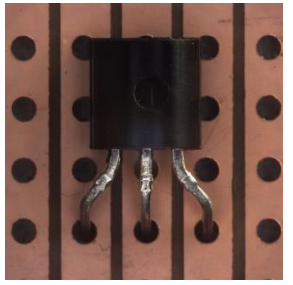
bottle



pill



leather



transistor

数据挖掘导论2026大作业

任务 2：图像异常检测任务　　25% Score

设计并完成图像异常检测算法，并阐明你的设计思路。

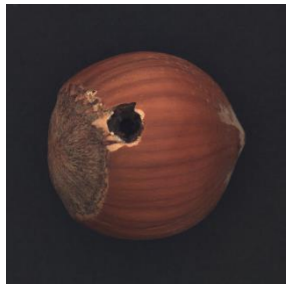
2.0：问题的形式化描述	5% Score
2.1 ：**如何**处理图像特征	5% Score
2.2 ：**完成异常**检测模型，并简述你的设计思想	10% Score
2.3 ：评估你的异常检测效果	5% Score

图像异常检测数据集Image_Anomaly_Detection，**包含2个**类别(hazelnut/zipper)**的数据。每个**类别训练集中包含正常样**本**200张，异常样本50张；测试集包含正常、异常样本。

hazelnut



normal



bad

zipper



normal



bad

数据挖掘导论2026大作业

任务 3：时间序列预测任务　　25% Score

选择合适的预测（回归）算法，并阐明你的设计思路。

3.0：问题的形式化描述	5% Score
3.1 ：**数据**预处理 + 训练/测试集划分	5% Score
3.2 ：**完成**时间序列预测模型，并阐述你的设计思想	10% Score
3.3 ：评估你的预测效果	5% Score

时间序列预测数据集Weather（weather.csv）：德国某气象站半年之内的21个气象学指标的变化情况。每隔10min记录一次

数据点总数：26200

数据特征维度：21

预测目标：用过去2小时（12个时间点）的全部指标，预测下一时间点二氧化碳浓度CO2 (ppm)。

要求：

- 针对数据进行特征标准化以及滑动窗口切分；定义训练集与测试集。
- 设计时间序列预测模型，根据过去2小时（12个时间点）的情况，预测下一时间点二氧化碳浓度CO2 (ppm) 的变化
- 选择合适的误差指标，在测试集上评估并分析预测效果。

数据挖掘导论2026大作业

任务 4：无监督疾病判断任务　　25% Score

选择合适的无监督算法判断是否患病，并阐明你的设计思路。

4.0： 问题的形式化描述	5% Score
4.1 ：选择合适的无监督方法，并阐述你的理由	5% Score
4.2 ：实现模型并训练（如有必要）	10% Score
4.3 ：评估你的判断效果	5% Score

疾病判断数据集Thyroid：**来自某医**疗机构的甲状腺疾病数据,

- **数据点**总数：3772（训练集与测试集总数）
- **数据特征**维度：6 （该指标经过脱敏处理）

训练集中的均为正常样本（不患病）， 测试集中同时包含患病（label=1）**/不患病**样本（label=0）， 请你在训练集上训练你的模型，并在测试集上进行判断。

要求：

1、**分析数据特点**，选择合适的无监督方法，并阐述理由。
2、**学**习训练集中正常样本的特点（提示：与正常样本规律不同的即为异常点）
3、选择合适的指标，在测试集上评估模型的效果

数据挖掘导论2026大作业

拓展作业一：跨模态异常检测　　**拓展作**业为自愿加分项，两项任选一项，最高加 10 分。

请回想课上关于“**异常**检测”**相关的定**义，并思考：

任务2**和任**务4**是两种不同模**态的异常检测任务，分析两种模态异常检测任务的异同，是否可以想到一**种框架/方法同**时检测出两种模态的异常（有监督/**无**监督设置均可）？如果你认为无法统一多种模态的异常检测，也可给出理由。

数据挖掘导论2026大作业

拓展作业二：企业财务问答Agent系统　　**拓展作**业为自愿加分项，两项任选一项，最高加 10 分。

任务：设计可复用的大模型Agent，自主选择查询数据库、检索年报或计算指标，给出有依据的回答。可使用LangChain/LangGraph、Deep Agents、DeepSeek Harness（DSH），或OpenAI Agents SDK、Claude Agent SDK等框架、harness或SDK。

问题示例（中文意译）：

- Snowflake：公司收入增长总体呈现怎样的趋势?
- Snowflake：公司重点强调了哪些产品与技术举措?

Agent需要根据问题使用道具、检索数据库、计算指标，进行回答。

数据：FinanceQA.zip，包含SQLite财务数据库与9份年报正文（HTML）。

共6家公司、56题：train为4家公司37题；test为2家公司19题。

train：可使用对应参考答案与评测反馈Agent系统开发和优化，不要求训练模型参数。

test：固定方法后自动完成全部问题；**不能使用 test 参考答案或评分反馈Agent设计！**

数据挖掘导论2026大作业

拓展作业二：完成要求与评测 二选一，最高加10分

任务提示：

可以先建立基础 Agent 完成任务，再选择一个优化方向，例如：

1. 构建适合 Agent 访问的数据结构，如指标映射、检索目录、语义视图或索引。
2. 用 Skill 组织指标定位、口径检查等过程。
3. 用 memory 保存 train 阶段验证过的规则、查询模式和失败经验。

独立评测：

作答完成后运行包内evaluate.py；具体命令见evaluation_only/评测说明.md。

检查器比较回答与原问题、参考答案，判定“支持”“矛盾”或“信息不足”，并统计支持率。

按完成情况、系统设计和实验分析综合评价，自动支持率不直接换算为作业得分。

数据挖掘导论2026大作业

提交要求：每个小组的组长提交

1. 位置： https://bhpan.buaa.edu.cn/link/AA6BCC225FF5224905A559D17A40BA163D

   文件夹名：数据挖掘导论2026大作业

2. 提交压缩包标题格式：学号1_姓名1_学号2_姓名2_学号3_姓名3_数据挖掘导论2026课程大作业

3. 内容：

   · 实现报告 pdf， 需要说明清楚每个任务的方法和实验结果（后续给出模版）

   · 代码仓库链接（注意提交在程序运行的readme）

   · 小组分工明细表（姓名+百分比）

4. 截止日期： 校历16周周日（2026年12月27日）23:59之前提交